비전 AI 모델 테스트 보고서

YOLOE · DINO-X · SAM 3 · SigLIP 2 · OCR · MediaPipe

작성일: 2026. 10. 12.
작성자: 김이환

1. 개요

1.1 목적

최근 공개된 주요 비전 AI 모델 여섯 가지를 직접 실행해 보고, 각 모델의 기능과 특성, 실제 동작 결과를 정리한다. 특히 공장 컨베이어 벨트 위 대상물의 결함 검출처럼 엣지 디바이스에서 동작해야 하는 영상 분석 업무에 어떤 모델을 어떤 역할로 활용할 수 있는지를 검토하는 데 목적이 있다.

1.2 테스트 대상 및 방법

전반적인 모델은 Colab으로 라이브러리를 통해 모델을 불러와 실행했다. MediaPipe는 웹 데모를 통해 구동하였다.

모델	분류	테스트 방식
YOLOE	Open-vocabulary 실시간 검출·분할	Colab 직접 구현
DINO-X	Open-world 범용 객체 인식	웹 데모
SAM 3	개념 기반 분할 및 추적	Colab 직접 구현
SigLIP 2	이미지-텍스트 인코더	Colab 직접 구현
OCR	문자 검출·인식	Colab 직접 구현
MediaPipe	온디바이스 인식 프레임워크	웹 데모

1.3 모델 요약 비교

※ 발표 시기, 공개 형태 등은 작성 시점 기준 정보이며 제출 전 각 공식 페이지에서 재확인이 필요하다.

모델	주요 작업	입력(프롬프트)	출력	공개 형태	엣지 적합성
YOLOE	Open-vocab 검출 + 인스턴스 분할	텍스트, 시각 예시, 프롬프트 없음	박스, 마스크	오픈소스 (Ultralytics 지원)	높음
DINO-X	Open-world 검출, 분할, 키포인트, 객체 설명	텍스트, 시각 예시, 프롬프트 없음	박스, 마스크, 키포인트, 텍스트	Pro는 API 중심, Edge 버전 별도	낮음~중간 (클라우드 의존)
SAM 3	개념 기반 분할, 영상 추적	명사구 텍스트, 예시 이미지, 점·박스	마스크, 객체 ID	가중치 공개 (사용 신청)	낮음 (대형 모델)
SigLIP 2	이미지-텍스트 임베딩, zero-shot 분류	이미지 + 텍스트 라벨	임베딩, 유사도	오픈 웨이트	중간 (비전 인코더만 탑재 시)
OCR	문자 영역 검출 + 인식	이미지	문자열, 위치	엔진별 상이	경량 엔진은 높음
MediaPipe	손·얼굴·자세 랜드마크 등	이미지, 영상	랜드마크 좌표, 박스 등	오픈소스	매우 높음

2. YOLOE

2.1 개요

YOLOE(Real-Time Seeing Anything)는 칭화대 연구팀이 2025년에 공개한 모델로, YOLO 계열의 실시간 검출기를 open-vocabulary로 확장한 것이다. 기존 YOLO는 학습 때 정한 클래스(예: COCO 80종)만 검출할 수 있지만, YOLOE는 텍스트나 예시 이미지로 찾을 대상을 그때그때 지정할 수 있고, 프롬프트 없이도 화면 속 물체를 스스로 찾아 이름을 붙인다. 검출 박스와 인스턴스 분할 마스크를 하나의 모델에서 함께 출력한다.

2.2 핵심 기술 및 기능

세 가지 프롬프트 방식을 하나의 모델에서 지원하는 것이 핵심이며, 각각에 전용 모듈을 둔다.

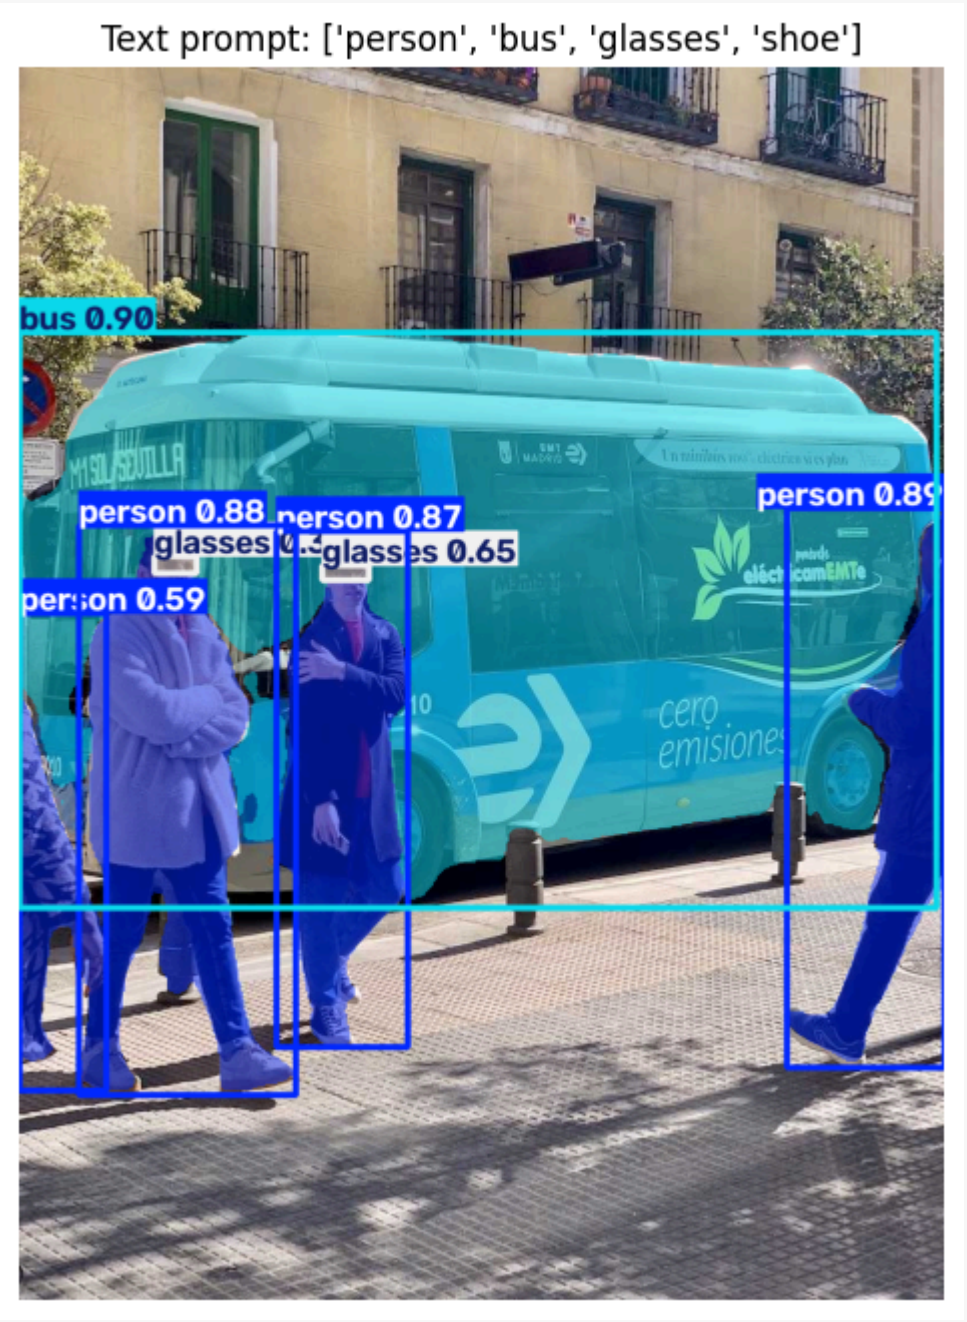
모드	입력	가중치	언제 쓰나
1. 텍스트 프롬프트	클래스 이름 리스트 (`["person", "bus"]`)	`yoloe-*-seg.pt`	찾을 대상을 말로 표현할 수 있을 때
2. 비주얼 프롬프트	예시 이미지 + 박스	`yoloe-*-seg.pt`	말로 설명하기 어려운 대상 (특정 부품, 결함 모양 등)
3. 프롬프트 프리	없음 (내장 대규모 어휘)	`yoloe-*-seg-pf.pt`	이미지에 뭐가 있는지 전부 보고 싶을 때

- **텍스트 프롬프트 (RepRTA):** 사전학습된 텍스트 임베딩을 작은 보조 네트워크로 보정한다. 추론 시에는 이 보조 네트워크를 분류 헤드에 재파라미터화(re-parameterization)해 합쳐 넣기 때문에, 클래스를 정해두면 일반 YOLO와 같은 속도로 동작한다.
- **시각 프롬프트 (SAVPE):** 박스 등으로 지정한 예시 영역에서 의미 정보와 위치 활성화 정보를 분리해 인코딩한다. 말로 설명하기 어려운 대상을 예시 한 장으로 지정할 때 유용하다.
- **프롬프트 없음 (LRPC):** 내장된 대규모 어휘와 검출된 영역만 비교(lazy matching)하는 방식으로, 별도의 언어 모델 없이 가볍게 물체 이름을 붙인다.
- Ultralytics 패키지에 통합되어 있어 기존 YOLO와 같은 방식으로 학습, 추론, ONNX·TensorRT 내보내기가 가능하다.

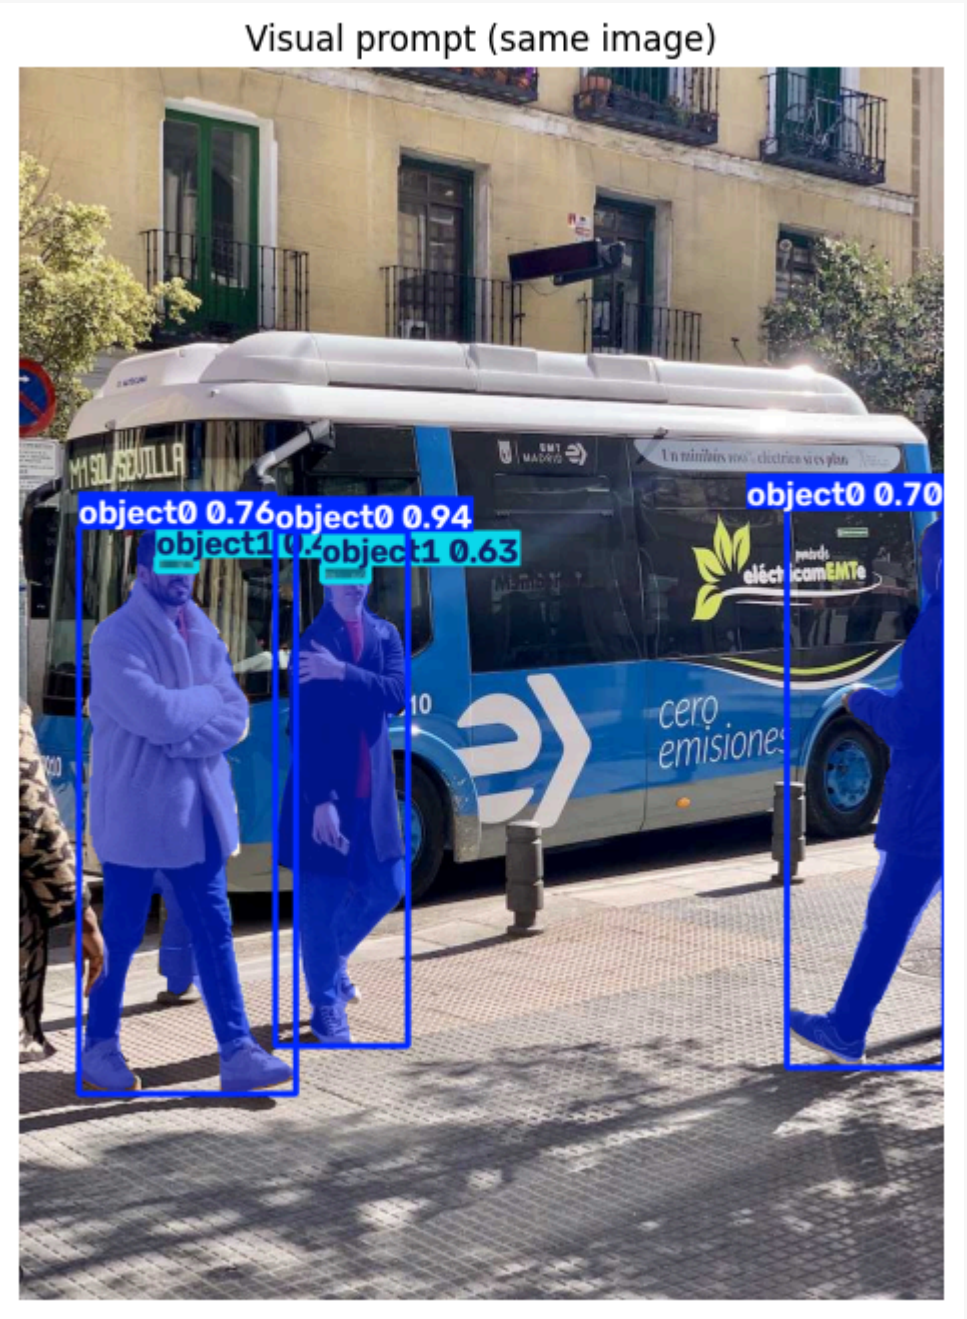
2.3 테스트 환경

실행 환경	Colab
사용 모델	yoloe-26s-seg
프롬프트 / 설정	CONF = 0.25

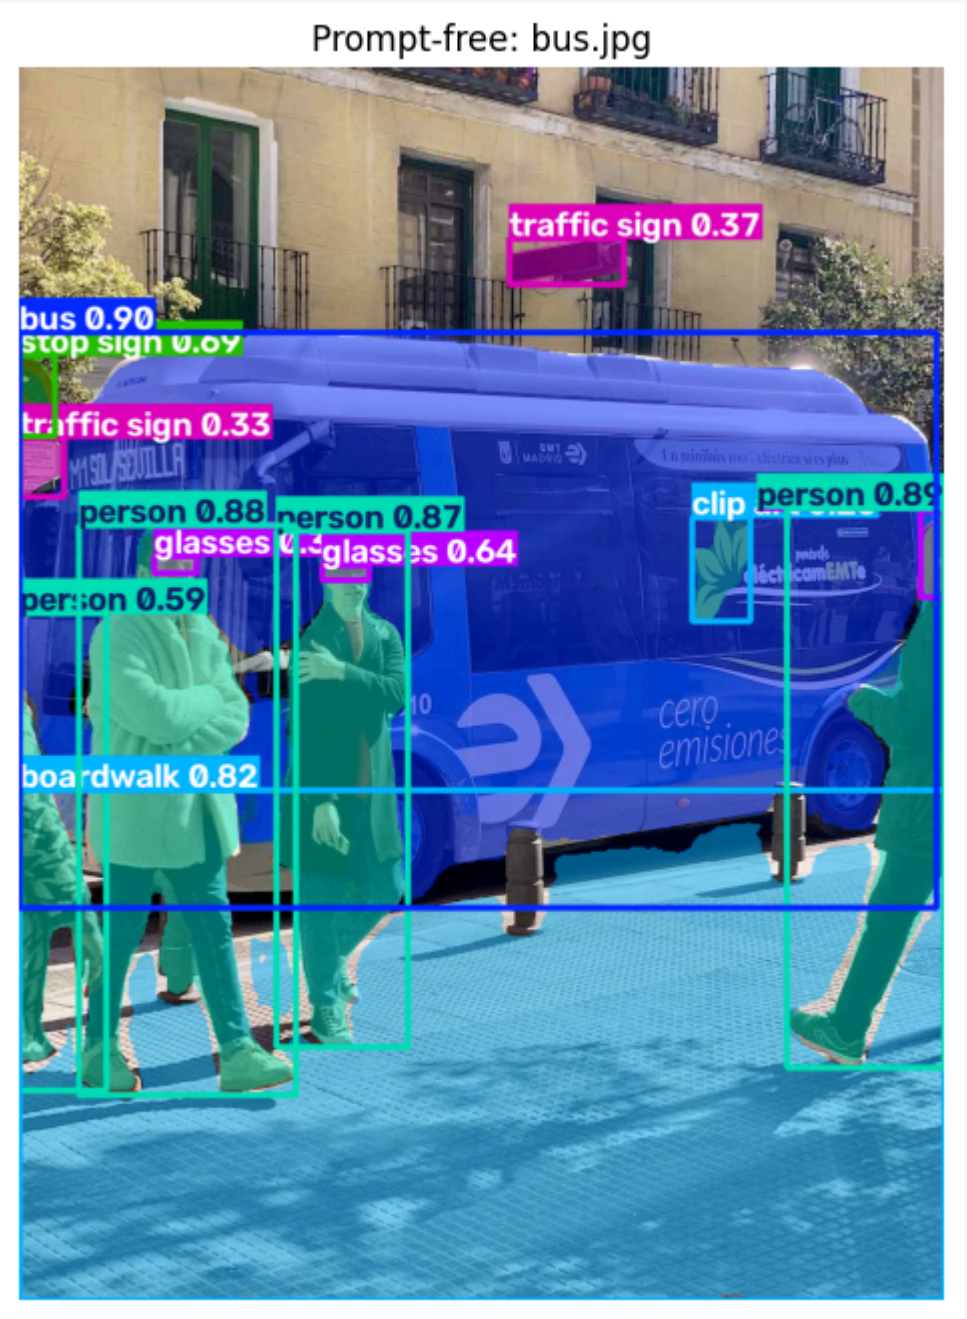
2.4 테스트 결과



텍스트 프롬프트 검출·분할 결과


Visual prompt (same image)
object0 0.76
object0 0.94
object1 0.63
object0 0.70
cero
emisiones

시각 프롬프트 모드 결과



프롬프트 없음(prompt-free) 모드 결과

관찰 내용: 전체적으로 인식하는 Prompt-free부터 특정 타겟 (Text & Visual)을 하는 모드 중 선택해서 사용해야 한다.

2.5 장단점 및 활용 가능성

장점	한계
• 실시간 속도를 유지하면서 클래스를 자유롭게 지정 가능 • 검출과 분할을 한 번에 출력	• 대형 모델 대비 미세하거나 생소한 개념의 인식 정확도는 낮을 수 있음 • 프롬프트 문구에 따라 결과 편차가 있음

• YOLO 생태계(학습, 내보내기, 배포 도구)를 그대로 활용	• 산업 결함처럼 학습 분포 밖의 대상은 추가 학습(fine-tuning) 필요

여섯 모델 중 엣지 배포에 가장 가까운 모델이다. 검사 대상 클래스가 확정되면 텍스트 임베딩을 고정해 일반 YOLO처럼 경량 배포할 수 있고, 라인 품목이 바뀔 때 재학습 없이 프롬프트만 바꿔 대응하는 시나리오도 가능하다. 결함 자체의 판정보다는 컨베이어 위 대상물 위치 검출·분할 후 결함 판정 모델로 넘기는 1단계 역할에 적합하다.

3. DINO-X

3.1 개요

DINO-X는 IDEA Research가 2024년 말 발표한 범용 객체 중심(object-centric) 비전 모델로, Grounding DINO 계열을 잇는 open-world 객체 인식 모델이다. 텍스트·시각 프롬프트로 원하는 대상을 찾는 것은 물론, 프롬프트 없이 장면 속 모든 객체를 검출하는 것을 목표로 한다. 고성능의 Pro 버전과 엣지 장치용으로 최적화한 Edge 버전으로 나뉜다.

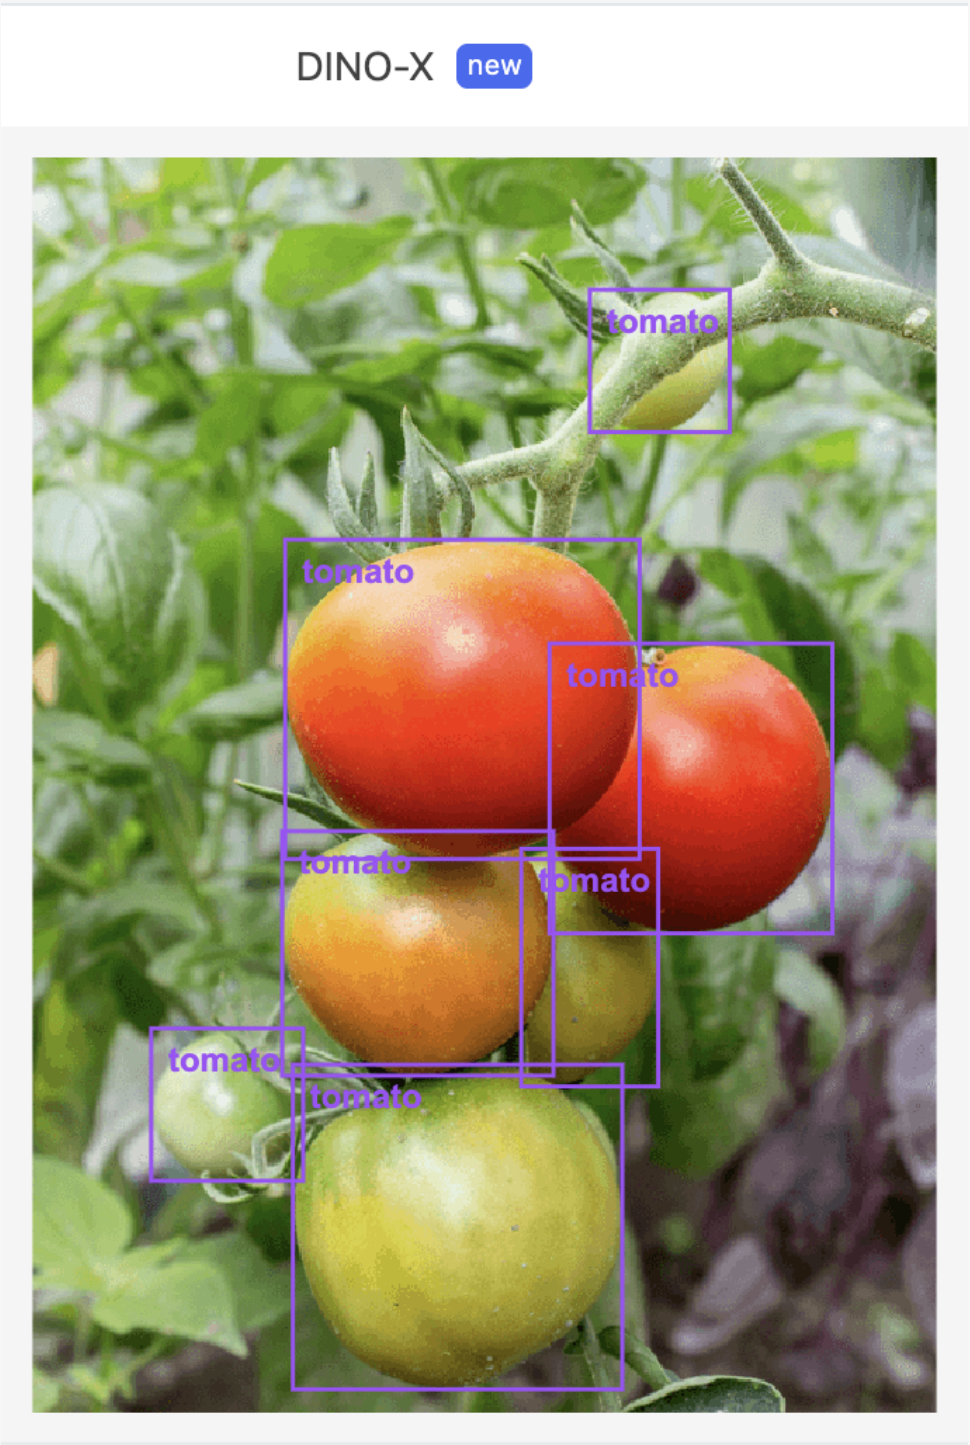
3.2 핵심 기술 및 기능

- **Transformer 인코더-디코더 구조:** DINO 계열 검출 구조를 기반으로 하며, 대규모 grounding 데이터셋(Grounding-100M)으로 사전학습해 open-world 인식 성능을 높였다.
- **다양한 프롬프트:** 텍스트 프롬프트, 시각 프롬프트, 특정 대상을 위해 학습시키는 사용자 정의 프롬프트, 그리고 프롬프트 없는 범용 검출을 지원한다.
- **멀티 헤드 출력:** 하나의 백본 위에 박스 검출, 분할 마스크, 키포인트(사람 자세, 손), 객체 단위 설명 생성(언어 헤드) 등 여러 인식 헤드를 올려 다양한 작업을 함께 수행한다.
- **제공 방식:** Pro 버전은 주로 클라우드 API 형태로 제공되며, 실시간 처리를 위한 Edge 버전이 별도로 존재한다.

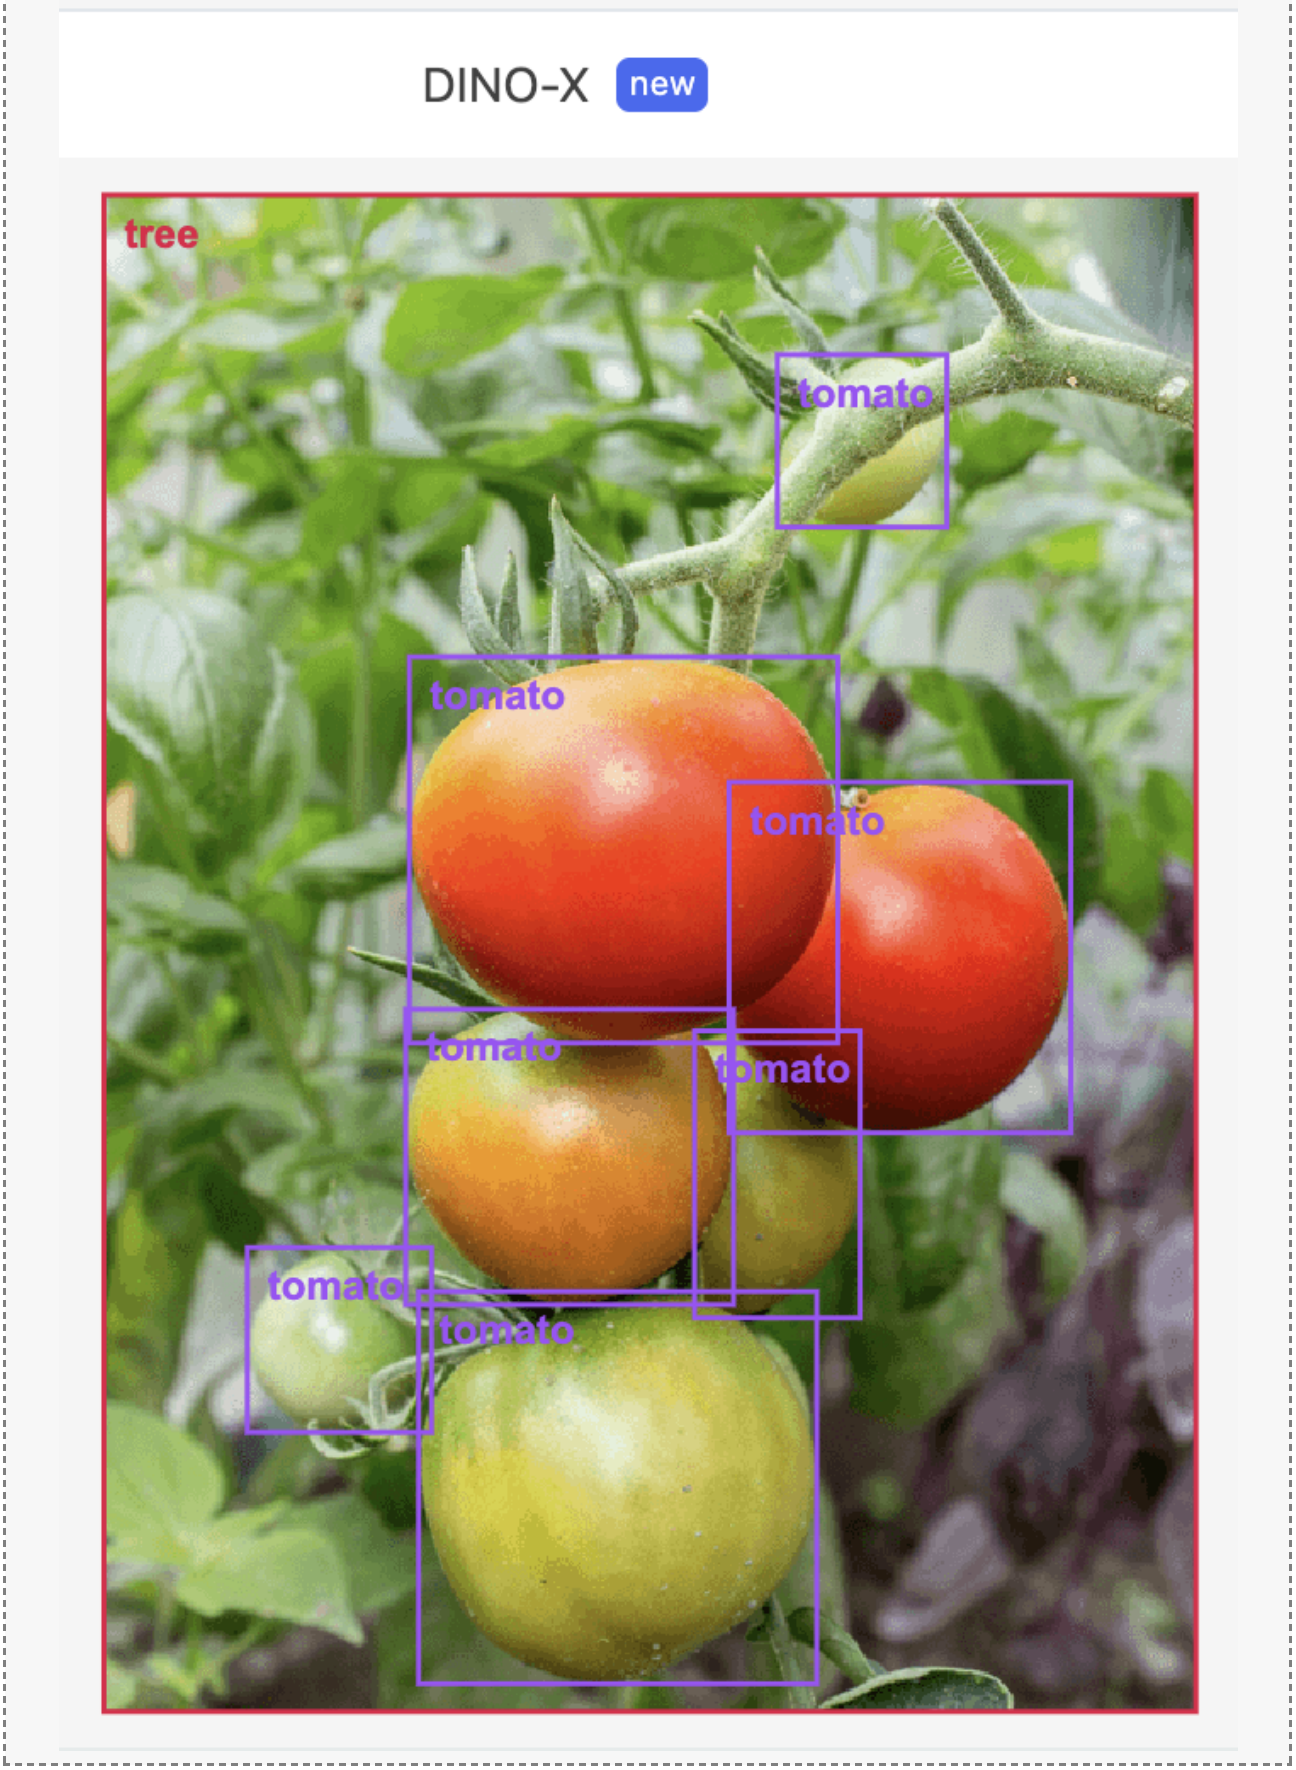
3.3 테스트 환경

실행 환경	웹 데모
사용 모델	DINO-X

3.4 테스트 결과



DINO-X 검출 결과 (텍스트 프롬프트)



DINO-X 검출 결과 (프롬프트 프리)

관찰 내용: 동작 자체는 YOLOE와 거의 동일하나 이는 유료 모델이기에 도입이 어렵다.

3.5 장단점 및 활용 가능성

장점	한계
• 희귀하거나 생소한 물체까지 폭넓게 인식하는 open-world 성능 • 검출·분할·키포인트·설명을 하나의 모델로 처리 • 프롬프트 없이도 장면 전체를 파악 가능	• 고성능 버전은 클라우드 API 의존으로 네트워크 지연, 비용, 데이터 외부 전송 문제 발생 • 로컬 커스터마이징·재학습의 자유도가 오픈소스 모델보다 낮음 • 공장 내 폐쇄망 환경에서는 적용 어려움

현장 실시간 판정용보다는 오프라인 분석과 학습 데이터 구축 단계에 적합하다. 예를 들어 라인에서 수집한 이미지에 **DINO-X로 1차 라벨을 자동 생성**하고, 이를 검수해 경량 모델 **학습 데이터로 쓰는 방식**이 현실적이다. Edge 버전의 실제 배포 조건(라이선스, 지원 하드웨어)은 별도 확인이 필요하다.

4. SAM 3 (Segment Anything Model 3)

4.1 개요

SAM 3는 Meta가 2025년 11월 공개한 Segment Anything 시리즈의 세 번째 모델이다. SAM 1·2가 사용자가 찍은 점이나 박스 위치의 물체 하나를 분할하는 데 집중했다면, SAM 3는 "노란 스쿨버스"처럼 짧은 명사구나 예시 이미지로 개념을 지정하면 이미지·영상 속 해당 개념의 모든 인스턴스를 찾아 분할하고 추적한다. Meta는 이를 Promptable Concept Segmentation(PCS)이라고 부른다.

4.2 핵심 기술 및 기능

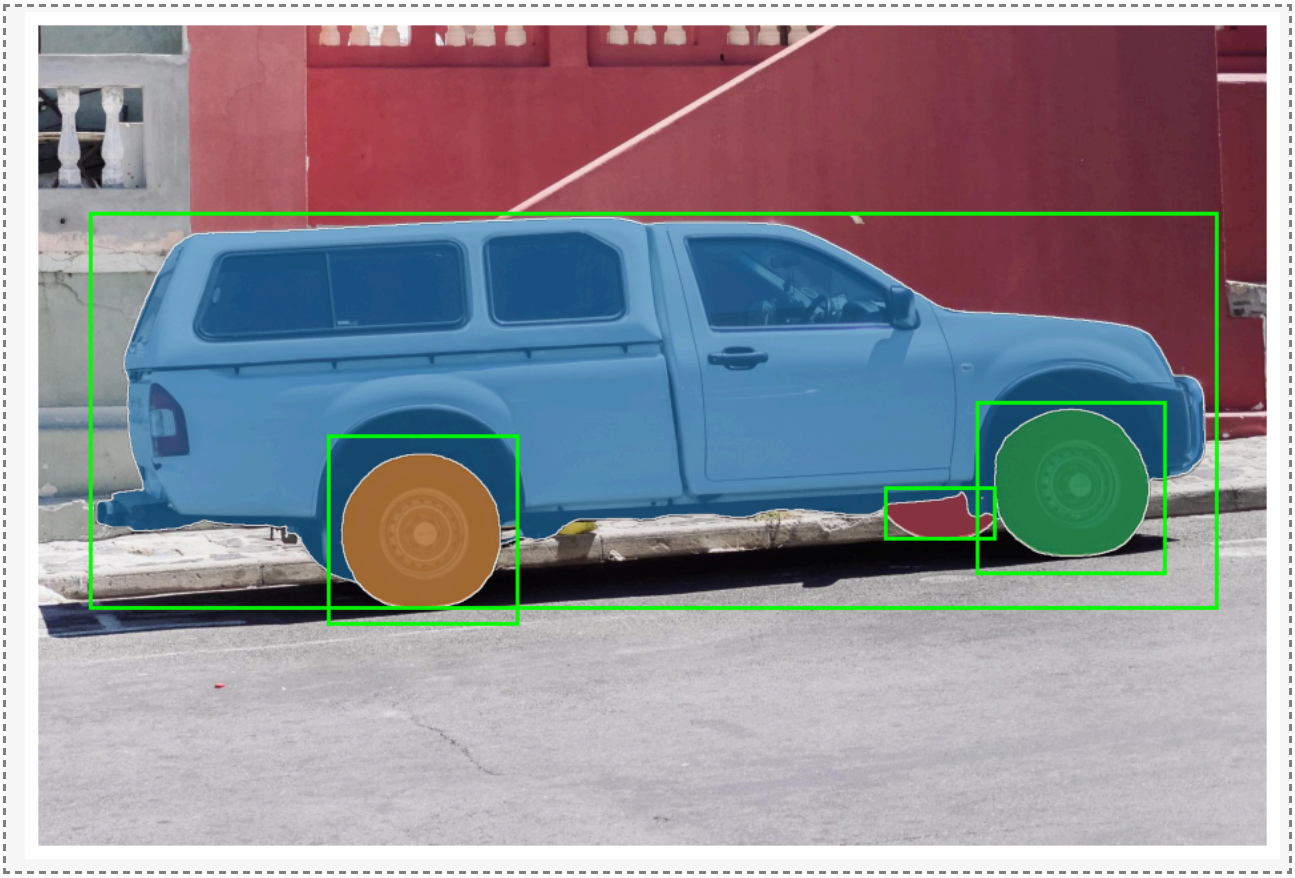
- **개념 프롬프트:** 텍스트 명사구 또는 예시 이미지(exemplar)로 대상 개념을 지정한다. 긍정·부정 예시를 추가해 결과를 다듬을 수 있다.
- **기존 기능 유지:** SAM 2의 점·박스·마스크 기반 시각 프롬프트 분할과 영상 추적 기능도 그대로 지원한다.
- **검출기 + 추적기 구조:** 공통 비전 인코더 위에 이미지 단위 검출기와 영상용 메모리 기반 추적기를 둔다. 또한 개념이 이미지에 존재하는지를 판단하는 부분(presence head)을 위치 찾기와 분리해, 비슷하지만 다른 개념을 혼동하는 문제를 줄였다.
- **대규모 데이터 엔진:** 사람과 AI 검수를 결합한 데이터 엔진으로 매우 많은 수의 개념에 대한 분할 데이터를 구축했고, 이를 평가하는 SA-Co 벤치마크를 함께 공개했다.

4.3 테스트 환경

실행 환경	Colab
사용 모델	SAM 2

4.4 테스트 결과





관찰 내용: 상세한 오브젝트 위치 및 경계 구분 가능하다. 다만 엣지 디바이스에 사용하기엔 모델 크기와 추론시간 등이 적합하지 않다.

4.5 장단점 및 활용 가능성

장점	한계
• 텍스트 한 줄로 해당 개념의 모든 인스턴스를 정밀 분할 • 이미지와 영상(추적)을 하나의 모델로 처리 • 가중치가 공개되어 로컬 실행·연구 활용 가능	• 모델 규모가 커서 GPU 서버 수준의 자원 필요, 엣지 실시간 처리 어려움 • 짧은 명사구 위주라 복잡한 문장·관계 표현은 제한적 • 산업 결함 같은 특수 개념은 인식이 약할 수 있음

현장 장비에 직접 올리기보다 학습 데이터 제작 도구로 가치가 크다. 결함 검출 모델을 학습하려면 정밀한 분할 라벨이 필요한데, SAM 3로 대상물 마스크를 자동 생성하고 사람이 수정하면 라벨링 시간을 크게 줄일 수 있다. 이렇게 만든 데이터로 YOLO 계열 등 경량 모델을 학습해 엣지에 배포하는 교사(teacher)-학생(student) 구조가 적합하다.

5. SigLIP 2

5.1 개요

SigLIP 2는 Google DeepMind가 2025년 2월 공개한 이미지-텍스트 인코더로, 이미지와 텍스트를 같은 임베딩 공간에 매핑해 둘이 얼마나 잘 맞는지 점수를 매긴다. 텍스트를 생성하는 모델이 아니라 임베딩과 유사도를 출력하는 모델이며, zero-shot 분류, 이미지-텍스트 검색, 다운스트림 작업용 특징 추출, VLM의 비전 인코더 등으로 쓰인다.

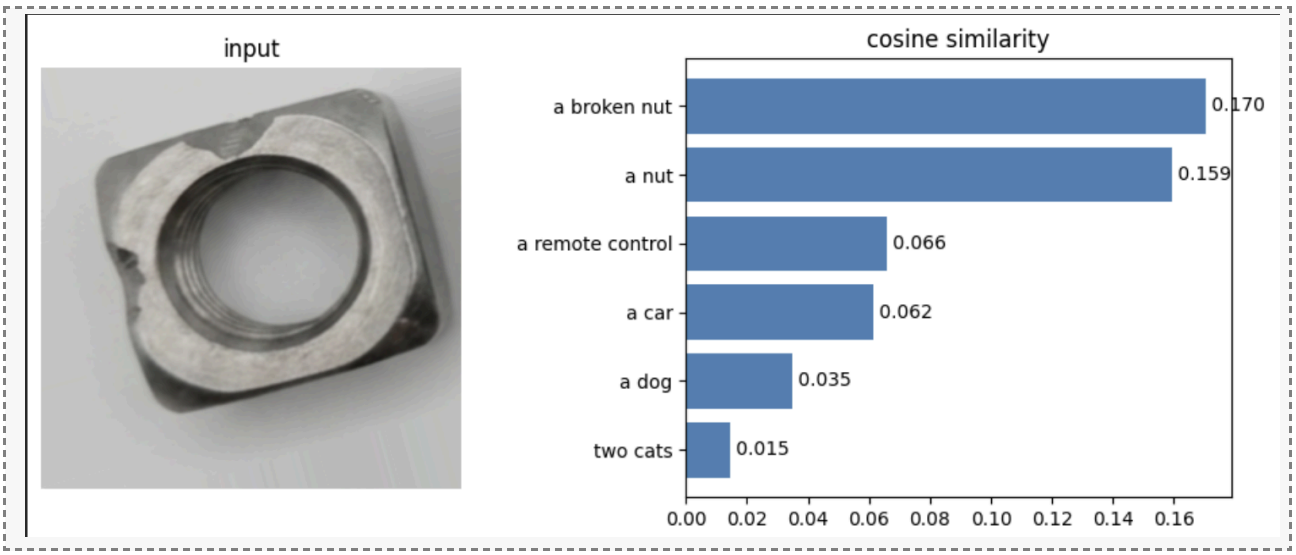
5.2 핵심 기술 및 기능

- **Sigmoid loss:** CLIP처럼 배치 전체에 softmax를 거는 대신, 각 이미지-텍스트 쌍을 독립적으로 '맞다/아니다'로 판단하는 sigmoid 손실로 학습한다. 따라서 출력 점수도 라벨별로 독립적이며 합이 1이 되지 않는다.
- **학습 기법 확장:** 캡셔닝 기반 사전학습(캡션 생성 및 영역 위치 예측), self-distillation, masked prediction을 추가해 전체 의미뿐 아니라 지역적·세밀한 특징(dense feature) 품질을 높였다.
- **다국어 및 NaFlex:** 다국어 데이터로 학습했으며, NaFlex 변형은 이미지 원본 비율과 다양한 해상도를 그대로 입력받는다.
- **모델 크기:** ViT-B(약 86M), ViT-L(약 303M), So400m(약 400M), ViT-g(약 1B)의 비전 인코더 크기로 제공된다.

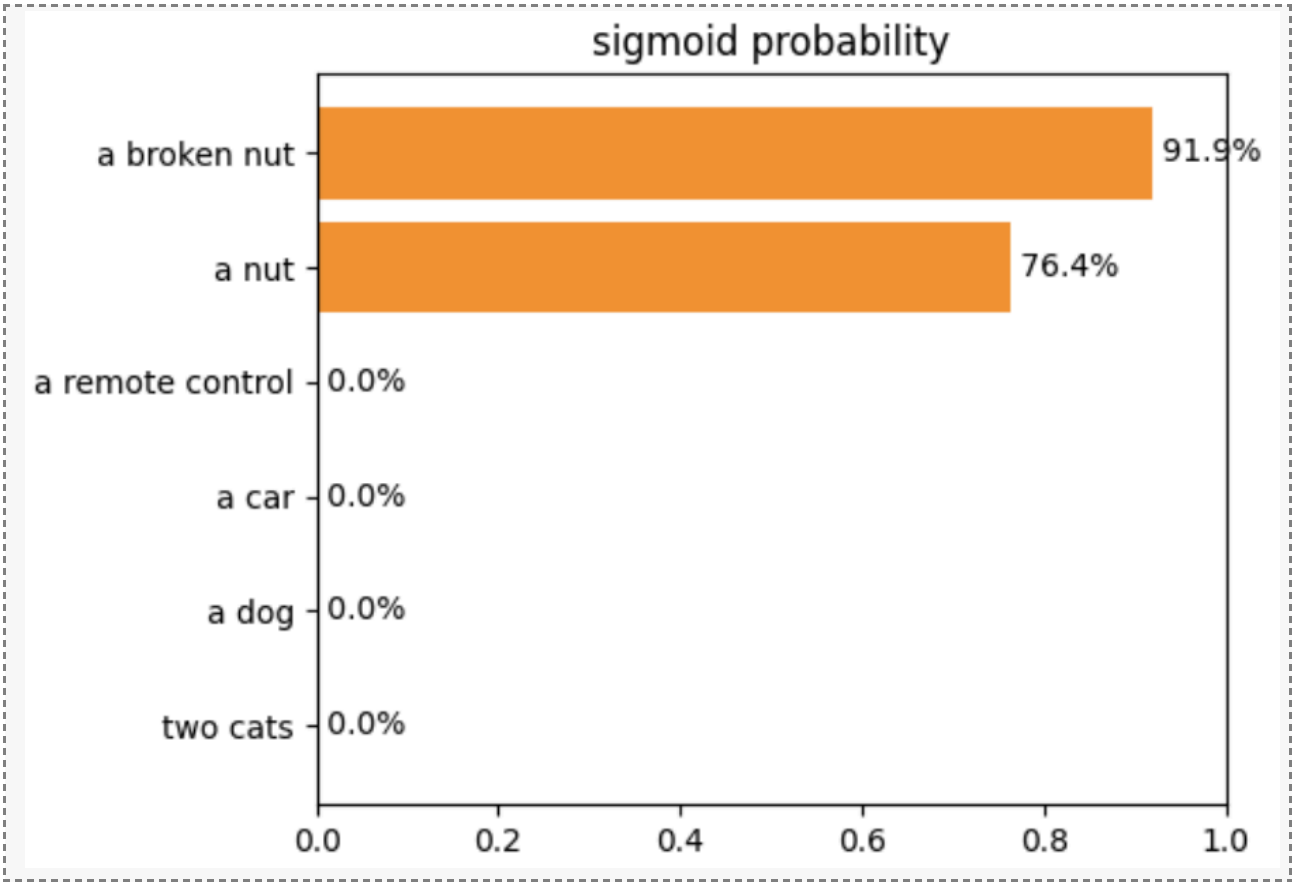
5.3 테스트 환경

실행 환경	Colab
사용 모델	google/siglip2-base-patch16-224

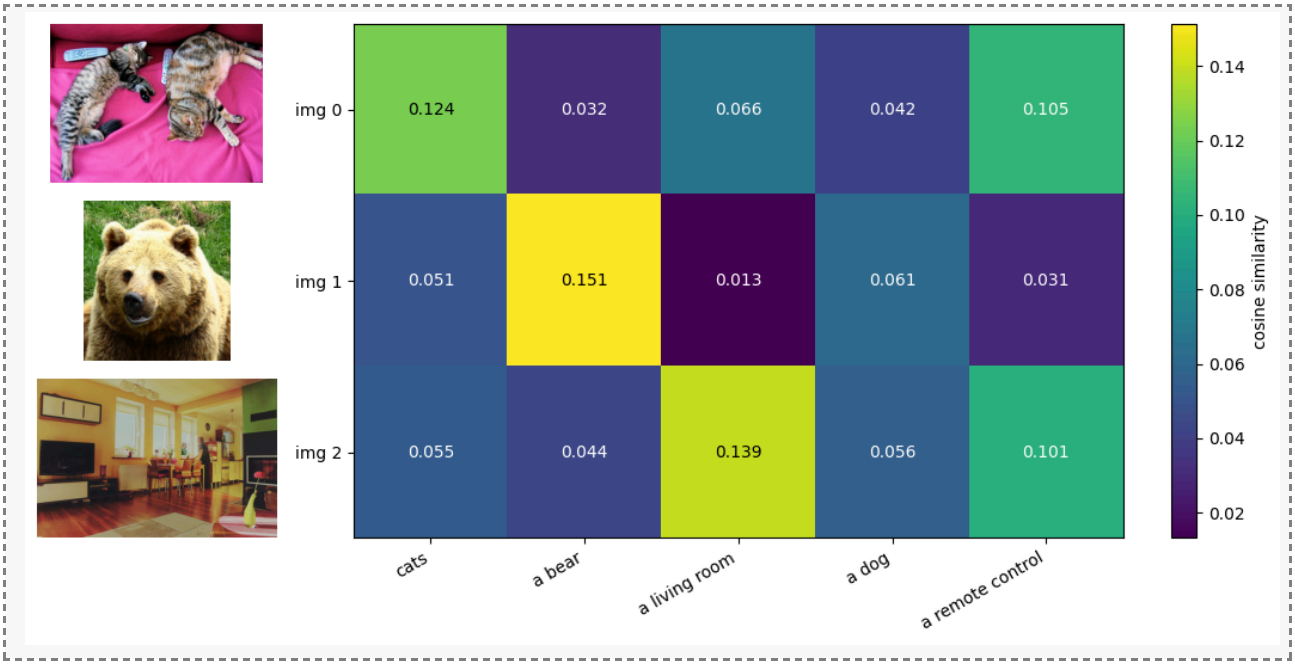
5.4 테스트 결과



실제 타겟 데이터로 결과 확인



위에 해당되는 sigmoid 확률



여러 이미지 × 여러 텍스트 유사도 히트맵

관찰 내용: 결과값이 충분히 사용가능하고 속도도 빠른 것으로 확인된다. 다만 목적 데이터, 공장의 것에 적용하기 위해서는 추가적인 확인이 필요하다.

5.5 장단점 및 활용 가능성

장점	한계
• 추가 학습 없이 텍스트 라벨만으로 분류 가능 (zero-shot) • 고품질 이미지 임베딩으로 소량 데이터 분류기(linear probe) 학습에 유리 • 오픈 웨이트, 여러 크기 선택 가능	• 점수가 calibration되지 않아 절대 임계값 설정이 어려움 (코사인 유사도는 상대 비교용) • 미세 크랙 등 작은 결함은 문장 유사도만으로 잡기 어려움 • 가장 작은 base 모델도 엣지 CPU에서는 수백 ms~1초대 소요 예상

테스트 결과, 코사인 유사도는 절대적인 확률이 아닌 상대 비교용 값이며, sigmoid 확률은 여기에 학습된 scale·bias를 적용한 값이라 두 값의 순위는 항상 일치함을 확인했다. 엣지 적용 시에는 고정된 라벨의 텍스트 임베딩을 미리 계산해 두고 비전 인코더(ViT-B)만 탑재하면 되므로, INT8 양자화 시 약 100MB 수준까지 줄일 수 있다.

다만 현장 결함 판정에 zero-shot을 그대로 쓰기보다는, 비전 인코더를 특징 추출기로 고정하고 자사 데이터로 소형 분류기를 학습시키거나, 데이터 탐색·라벨링 보조 도구로 활용하는 편이 신뢰도 측면에서 적합하다.

6. OCR (광학 문자 인식)

6.1 개요

OCR은 이미지 속 문자를 찾아 텍스트로 변환하는 기술이다. 이번 테스트에서는 **easyocr**을(를) 사용했다. 최근 OCR 엔진은 대부분 딥러닝 기반 2단계 파이프라인으로 구성되며, 경량 모델은 엣지 장치에서도 실시간에 가깝게 동작한다.

6.2 핵심 기술 및 기능

- **문자 영역 검출:** 이미지에서 글자가 있는 영역을 찾는다 (DBNet 계열 등 분할 기반 검출기가 널리 쓰임).
- **방향 보정:** 회전되거나 뒤집힌 텍스트 영역의 방향을 분류해 바로 세운다 (엔진에 따라 선택 사항).
- **문자 인식:** 잘라낸 영역을 문자열로 변환한다 (CRNN, SVTR, Transformer 기반 인식기 등).
- **최근 동향:** 문서 레이아웃·표 구조 인식까지 포함하는 문서 파싱 모델과, VLM이 직접 글자를 읽는 방식도 확산되고 있다.

6.3 테스트 환경

실행 환경	Colab
사용 엔진·모델	easyocr

6.4 테스트 결과



OCR 검출 영역 및 인식 결과

관찰 내용: 결과가 잘 인식 된 것으로 확인되었으나, 이미지의 질에 따라 결과가 달라질 것으로 예상된다.

6.5 장단점 및 활용 가능성

장점	한계
• 성숙한 기술로 오픈소스 엔진과 경량 모델 선택지가 많음 • 경량 모델은 엣지 CPU에서도 동작 가능 • 로트 번호, 라벨, 시리얼 등 생산 이력 자동화에 직접 활용 가능	• 금속 각인·음각 문자, 반사, 저조도에서 인식률 저하 • 특수 폰트나 손상 문자는 추가 학습 필요 • 검출과 인식 2단계 구조라 단계별 오류가 누적될 수 있음

공장 환경에서는 제품·포장의 로트 번호, 시리얼, 라벨 판독과 이력 관리에 바로 적용할 수 있다.

정확도는 모델보다 촬영 조건(조명 각도, 초점, 해상도)에 크게 좌우되므로, 결함 검출과 마찬가지로 카메라·조명 고정이 선행되어야 한다.

7. MediaPipe

7.1 개요

MediaPipe는 Google이 제공하는 온디바이스 머신러닝 프레임워크로, 모바일·웹·데스크톱·임베디드 환경에서 실시간 인식 기능을 쉽게 구현하도록 학습된 모델과 처리 파이프라인을 함께 제공한다. 서버 없이 기기 안에서 CPU만으로도 실시간 동작하는 것이 가장 큰 특징이다.

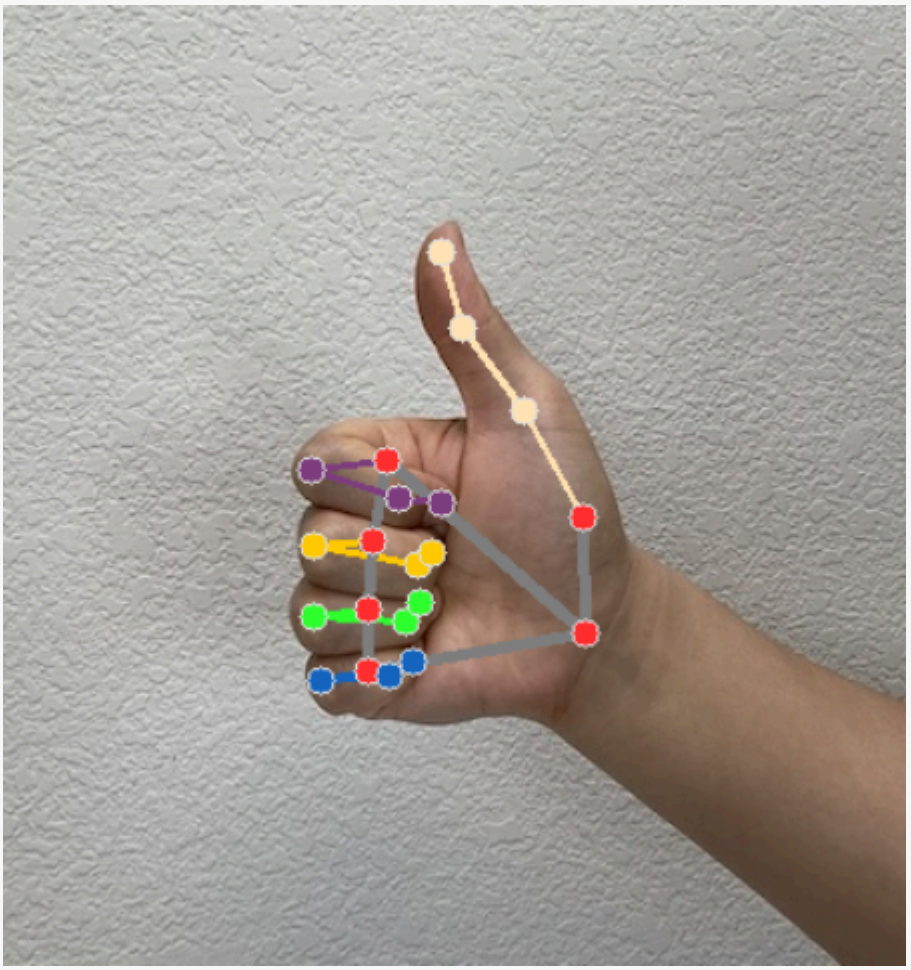
7.2 핵심 기술 및 기능

- **MediaPipe Tasks:** 손 랜드마크(21점), 제스처 인식, 얼굴 검출, 얼굴 랜드마크(478점 및 표정 계수), 자세 랜드마크(33점), 객체 검출, 이미지 분류, 이미지 분할, 이미지 임베딩 등 용도별 API를 제공한다.
- **경량 런타임:** LiteRT(구 TensorFlow Lite) 기반 경량 모델과 GPU 가속을 활용하며, 웹에서는 WebAssembly로 브라우저 안에서 바로 실행된다.
- **멀티 플랫폼:** Android, iOS, Web(JavaScript), Python을 지원하고, MediaPipe Studio에서 설치 없이 기능을 시험해 볼 수 있다.
- **커스터마이징:** Model Maker로 객체 검출·분류 등 일부 작업은 자체 데이터로 재학습할 수 있다.

7.3 테스트 환경

실행 환경	웹 데모
사용 Task	Hand Landmarker, Pose Landmarker

7.4 테스트 결과



MediaPipe 실행 결과 (랜드마크 등)

관찰 내용: 특정 기능을 위해서는 사용을 고려해볼 법하다. 다만, 이번 프로젝트 내에서는 사용이 힘들 것으로 보인다.

7.5 장단점 및 활용 가능성

장점	한계
• 모바일·웹 CPU에서도 실시간 동작하는 높은 효율 • 설치와 연동이 쉬운 완성형 파이프라인 제공 • 오픈소스, 다양한 플랫폼 지원	• 사람 중심(손·얼굴·자세) 작업 위주로, 산업용 물체 결함 검출에는 직접 쓰기 어려움 • 제공된 작업 범위 밖의 커스터마이징 자유도가 낮음 • 범용 객체 검출 성능은 최신 대형 모델보다 낮음

제품 결함 검출보다는 작업자 관련 기능에 적합하다. 예를 들어 위험 구역 내 손 진입 감지, 작업 자세 분석을 통한 안전·인체공학 모니터링, 장갑 착용 상태에서의 제스처 기반 장비 조작 등에 엣지 장치 하나로 적용할 수 있다.

8. 종합 비교 및 결론

8.1 엣지 적용 관점 정리

여섯 모델은 성능과 무게 사이에서 뚜렷하게 역할이 나뉜다. 대형 open-world 모델(DINO-X, SAM 3)은 인식 범위와 정밀도가 뛰어나지만 현장 장비에서 실시간으로 돌리기에는 무겁고, YOLOE와 MediaPipe는 실시간성이 뛰어나 현장 배포에 적합하다. SigLIP 2와 OCR은 그 중간에서 용도에 따라 경량화 여지가 있다.

모델	현장 배포 가능성	추천 역할	비고
YOLOE	높음	대상물 실시간 검출·분할	클래스 고정 후 일반 YOLO처럼 배포
DINO-X	낮음~중간	오프라인 자동 라벨링, 데이터 분석	Pro는 클라우드 API 의존
SAM 3	낮음	분할 라벨 자동 생성 (교사 모델)	GPU 서버 필요
SigLIP 2	중간	특징 추출, 데이터 탐색·분류 보조	비전 인코더만 탑재, 양자화 필요
OCR	높음 (경량 엔진)	로트 번호·라벨 판독	촬영 조건 영향 큼
MediaPipe	매우 높음	작업자 안전·자세 모니터링	물체 결함 검출 용도 아님

8.2 컨베이어 결함 검출 적용 방안

공장 컨베이어 벨트 위 대상물의 결함 검출에는 하나의 대형 모델을 그대로 현장에 올리기보다, 대형 모델을 오프라인 도구로 쓰고 경량 모델을 현장에 배포하는 구조가 현실적이다.

- **1단계 데이터 구축:** SAM 3, DINO-X로 수집 이미지의 대상물 영역과 마스크를 자동 생성하고 사람이 검수한다. SigLIP 2 임베딩으로 유사 이미지 군집화, 이상 샘플 탐색을 보조한다.
- **2단계 모델 학습:** 구축한 데이터로 YOLOE/YOLO 계열 경량 검출·분할 모델을 학습하거나, 정상 이미지만으로 학습하는 이상 탐지 모델(PatchCore, EfficientAD 등)을 적용한다.
- **3단계 현장 배포:** ONNX·TensorRT·OpenVINO 등으로 변환, 양자화해 라즈베리 파이 또는 Jetson급 엣지 장치에 배포하고, 필요 시 OCR로 제품 식별 정보를 함께 기록한다.
- **공통 전제:** 카메라 위치, 조명, 촬영 트리거를 고정해 입력 조건을 일정하게 만드는 것이 모델 선택보다 성능에 미치는 영향이 크다.

9. 참고 자료

※ 아래 링크는 작성 시점 기준이며, 제출 전 접속 여부와 내용을 확인할 것.

- YOLOE: Real-Time Seeing Anything — arxiv.org/abs/2503.07465 / github.com/THU-MIG/yoloe
- DINO-X: A Unified Vision Model for Open-World Object Detection and Understanding — arxiv.org/abs/2411.14347 / github.com/IDEA-Research/DINO-X-API
- SAM 3 — ai.meta.com/sam3 / github.com/facebookresearch/sam3
- SigLIP 2 — arxiv.org/abs/2502.14786 / huggingface.co/google/siglip2-base-patch16-224
- OCR — easyocr
- MediaPipe — ai.google.dev/edge/mediapipe